02_cleaning

September 8, 2026

1 02. Data Cleaning

Lanjutan dari `01_eda.ipynb`. Notebook ini membersihkan dataset mentah menjadi data siap-pakai (`data/processed/cleaned_data.csv`) dengan :

1. **Perbaikan kolom `Weight`** (kerusakan akibat auto-konversi Excel).
2. **Penanganan missing value** pada `Age (Month)` dan `Weight for Height`.
3. **Validasi** rentang nilai Weight (1–30 kg) yang masuk akal untuk balita.

Catatan: fitur turunan (`Weight for Age`, `Z-Score W/A`, `Z-Score H/A`, `Weight for Height`, `Z-Score W/H`) **tetap dibawa** di file output karena pemilihan fitur (dropping) dilakukan pada tahap preprocessing selanjutnya.

[1]:
```
import pandas as pd
import numpy as np
from datetime import datetime

pd.set_option("display.max_columns", None)
```

[2]:
```
RAW_PATH = "../data/raw/Overall Data.xlsx"
PROCESSED_PATH = "../data/processed/cleaned_data.csv"

df = pd.read_excel(RAW_PATH)
print("Shape awal:", df.shape)
```

```
Shape awal: (40071, 11)
```

1.1 1. Perbaikan Kolom `Weight`

Kolom `Weight` tercampur 3 tipe data akibat auto-konversi Excel:

- `datetime` → nilai desimal asli (misal `2025-02-08` → `8.2`, yaitu `day.month` (format DD.MM, umum di locale Indonesia/Eropa)).
- `int` / `str` numerik → dikonversi ke `float`.

Aturan konversi datetime mengikuti instruksi: `float(f"{day}.{month}")`.

[3]:
```
print("Sebelum perbaikan - tipe data per nilai pada kolom Weight:")
print(df["Weight"].map(type).value_counts())
```

```
Sebelum perbaikan - tipe data per nilai pada kolom Weight:
Weight
<class 'datetime.datetime'>    20158
<class 'int'>                  10780
<class 'str'>                   9133
Name: count, dtype: int64
```

[4]:
```python
def fix_weight_value(x):
    if isinstance(x, datetime):
        return float(f"{x.day}.{x.month}")
    if isinstance(x, bool):
        return float(x)
    if isinstance(x, (int, float)):
        return float(x)
    if isinstance(x, str):
        return float(x.strip())
    return np.nan


df["Weight"] = df["Weight"].apply(fix_weight_value)
print("Dtype Weight setelah konversi:", df["Weight"].dtype)
print("Jumlah NaN baru pada Weight:", df["Weight"].isna().sum())
```

```
Dtype Weight setelah konversi: float64
Jumlah NaN baru pada Weight: 0
```

1.2 Validasi Rentang Weight (1–30 kg)

Setelah konversi, cek apakah semua nilai berada pada rentang masuk akal untuk berat badan balita (±1–30 kg).

[5]:
```python
low_mask = df["Weight"] < 1
high_mask = df["Weight"] > 30

print(f"Weight < 1 kg : {low_mask.sum()}")
print(f"Weight > 30 kg: {high_mask.sum()}")
print("Nilai Weight > 30 kg:", sorted(df.loc[high_mask, "Weight"].unique()))
```

```
Weight < 1 kg : 0
Weight > 30 kg: 6
Nilai Weight > 30 kg: [np.float64(91.0), np.float64(2800.0), np.float64(2900.0),
np.float64(3000.0), np.float64(3085.0), np.float64(3100.0)]
```

1.2.1 Penanganan Outlier Weight

Validasi menemukan dua jenis nilai di luar rentang wajar:

1. **Nilai skala gram** (`2800, 2900, 3000, 3085, 3100`) — jelas merupakan berat bayi baru lahir yang tercatat dalam satuan **gram** (2,8–3,1 kg adalah berat lahir yang normal). Perbaikan: bagi 1000 → `2.8, 2.9, 3.0, 3.085, 3.1` kg.

2. **Nilai 91** — secara biologis mustahil sebagai berat balita (91 kg) dan tidak dapat dipastikan nilai aslinya. Karena hanya 1 baris, baris ini **dihapus** (drop) daripada ditebak.

[6]:
```
gram_mask = df["Weight"] >= 1000
n_gram = gram_mask.sum()
df.loc[gram_mask, "Weight"] = df.loc[gram_mask, "Weight"] / 1000
print(f"Nilai skala gram yang dikoreksi (dibagi 1000): {n_gram}")
print(df.loc[gram_mask, "Weight"].tolist())
```

```
Nilai skala gram yang dikoreksi (dibagi 1000): 5
[3.085, 3.1, 2.9, 3.0, 2.8]
```

[7]:
```
implausible_mask = (df["Weight"] < 1) | (df["Weight"] > 30)
print("Baris dengan Weight di luar 1-30 kg (akan di-drop):", implausible_mask.
  ↪sum())
print(df.loc[implausible_mask, ["No.", "Gender", "Age (Month)", "Weight",␣
  ↪"Height", "Weight for Height"]])
df = df.loc[~implausible_mask].reset_index(drop=True)
print("Shape setelah drop outlier Weight:", df.shape)
```

```
Baris dengan Weight di luar 1-30 kg (akan di-drop): 1
         No. Gender  Age (Month)  Weight  Height Weight for Height
26336  26337      F         28.0    91.0    84.0               NaN
Shape setelah drop outlier Weight: (40070, 11)
```

1.3 2. Penanganan Missing Value

1.3.1 Strategi: drop baris (bukan imputasi)

`Age (Month)` : 2 nilai hilang (0,005% dari 40.071). Usia adalah fitur numerik kunci, tetapi hanya 2 baris yang terdampak. Mengisi (imputasi) dengan median/mean akan menyuntikkan nilai sintetis yang tidak berasal dari pengukuran, sedangkan drop kehilangan data yang dapat diabaikan. → **drop**.

`Weight for Height` : 5 nilai hilang. Kolom ini adalah **fitur turunan** (dihitung dari berat & tinggi) yang sesuai metodologi justru **akan dibuang saat pemilihan fitur** untuk mencegah data leakage. Oleh karena itu imputasi tidak memberi manfaat apa pun bagi pemodelan, dan opsi paling sederhana & tidak bias adalah **drop** 5 baris tersebut.

[8]:
```
print("Missing value sebelum drop:")
print(df[["Age (Month)", "Weight for Height"]].isna().sum())
```

```
Missing value sebelum drop:
Age (Month)          2
Weight for Height    4
dtype: int64
```

[9]:
```
missing_mask = df["Age (Month)"].isna() | df["Weight for Height"].isna()
n_dropped_missing = missing_mask.sum()
df = df.loc[~missing_mask].reset_index(drop=True)
```

```
print(f"Baris di-drop karena missing value: {n_dropped_missing}")
print("Shape setelah drop missing value:", df.shape)
```

```
Baris di-drop karena missing value: 6
Shape setelah drop missing value: (40064, 11)
```

1.4 3. Validasi Akhir & Simpan

Pastikan tidak ada missing value tersisa dan seluruh `Weight` berada pada rentang wajar (1–30 kg), lalu simpan ke `data/processed/cleaned_data.csv`.

[10]:
```
print("Missing value total tersisa:", int(df.isna().sum().sum()))
print("Rentang Weight akhir:", df["Weight"].min(), "-", df["Weight"].max(),␣
↪"kg")
print("Weight di luar 1-30 kg:", int(((df["Weight"] < 1) | (df["Weight"] > 30)).
↪sum()))
print("Dtype Weight akhir:", df["Weight"].dtype)
print("Dtype Age (Month) akhir:", df["Age (Month)"].dtype)
```

```
Missing value total tersisa: 0
Rentang Weight akhir: 2.0 - 28.5 kg
Weight di luar 1-30 kg: 0
Dtype Weight akhir: float64
Dtype Age (Month) akhir: float64
```

[11]:
```
import os

os.makedirs(os.path.dirname(PROCESSED_PATH), exist_ok=True)
df.to_csv(PROCESSED_PATH, index=False)
print(f"Tersimpan: {PROCESSED_PATH}")
print("Shape akhir:", df.shape)
```

```
Tersimpan: ../data/processed/cleaned_data.csv


Shape akhir: (40064, 11)
```

1.5 4. Ringkasan Before / After Cleaning

[12]:
```
df_raw = pd.read_excel(RAW_PATH)

summary = pd.DataFrame({
    "Aspek": [
        "Jumlah baris",
        "Jumlah kolom",
        "Missing Age (Month)",
        "Missing Weight for Height",
        "Tipe campuran kolom Weight",
        "Dtype Weight",
```

```
        "Rentang Weight (kg)",
    ],
    "Before": [
        len(df_raw),
        df_raw.shape[1],
        int(df_raw["Age (Month)"].isna().sum()),
        int(df_raw["Weight for Height"].isna().sum()),
        "datetime/int/str",
        str(df_raw["Weight"].dtype),
        "tidak valid (datetime, gram, outlier)",
    ],
    "After": [
        len(df),
        df.shape[1],
        int(df["Age (Month)"].isna().sum()),
        int(df["Weight for Height"].isna().sum()),
        "seragam (numerik)",
        str(df["Weight"].dtype),
        f"{df['Weight'].min():.2f} - {df['Weight'].max():.2f}",
    ],
})
summary
```

[12]:

	Aspek	Before	After
0	Jumlah baris	40071	40064
1	Jumlah kolom	11	11
2	Missing Age (Month)	2	0
3	Missing Weight for Height	5	0
4	Tipe campuran kolom Weight	datetime/int/str	seragam (numerik)
5	Dtype Weight	object	float64
6	Rentang Weight (kg)	tidak valid (datetime, gram, outlier)	2.00 - 28.50

[13]:
```
print("Distribusi kelas target setelah cleaning:")
vc = df["Height for Age"].value_counts()
print(vc)
print((vc / len(df) * 100).round(2))
```

```
Distribusi kelas target setelah cleaning:
Height for Age
```

```
Not Stunted    23864
Stunted        16200
Name: count, dtype: int64
Height for Age
Not Stunted    59.56
Stunted        40.44
Name: count, dtype: float64
```